KØBENHAVNS UNIVERSITET

Open Data Science

Portfolio 1, 2 & 3

Eksaminand: Natascha Rylander Bech, TGZ940

Gruppe:

Natacha Rylander Bech, TGZ940

Martine Ingemann Jørgensen, JPR328

Stephanie Rose Acampado Soelmark, PZG932

Antal tegn i alt: 48724

6 januar, 2020

Indholdsfortegnelse

Portfolio 1

Denne opgave behandler Titanic datasættet, der indeholder data fra 887 passagerer. Herunder information om overlevelse, navn, alder med mere. Vi har analyseret denne data og i den forbindelse visualiseret resultaterne i form af tabeller. Denne rapport behandler således opgave 5 i opgavesættet.

Opgave 5 – Pivot-tabeller

Vi har først genereret en pivot-tabel der viser antal rejsende inden for hver klasse (med brug af pandas funktioner). I dette tabel-format kan man angive hvilken kolonne, der skal vises, og hvilken funktion, der skal behandle den. Dette har vi valgt at drage fordel af i vores tabel. Dermed definerer vi columns til 'Pclass' for at få de diverse klasser og anvender aggfunc, som udgør den definition man ønsker at anvende, til at definere count, da vi ønsker en optælling af alle rejsende opdelt i klasser (pandas.pivot_table, u.å). Herefter anvender vi plot(kind='bar'), således vi også kan få et visuelt output.

class_tabel = df_titanic.pivot_table(columns='Pclass', aggfunc={'Pclass':'count'})

print(class_tabel)

class_tabel.plot(kind='bar')

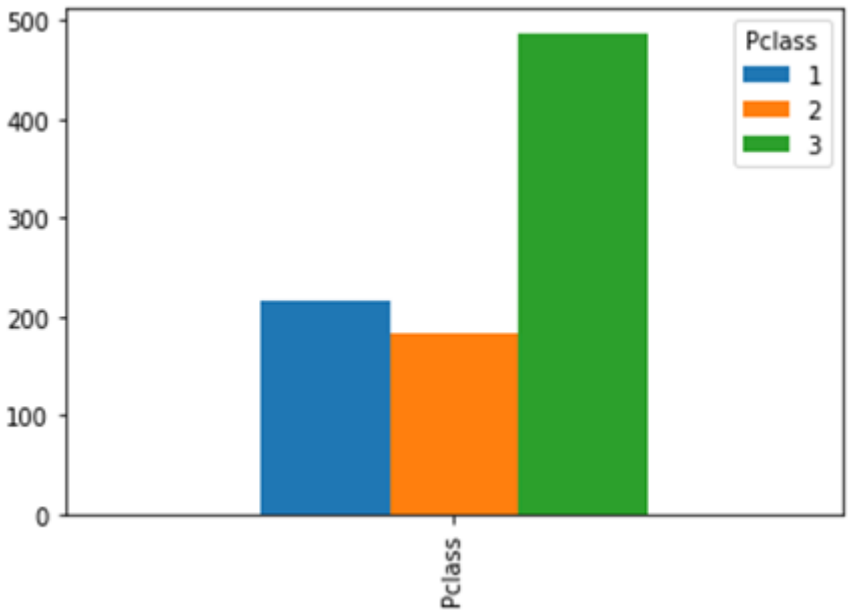

Således påvises det at der var 216 passagerer på første klasse, 184 på anden klasse og 487 på tredje klasse.

Herefter har vi lavet en pivot-tabel over antal overlevende og omkomne i hver klasse, hvor 0 er omkomne og 1 er overlevende. Funktionen optæller antallet for hver værdi i survived. Endnu engang har vi lavet en visuel fremstilling med plot(kind=’bar’) funktionen.

nyplot = df_titanic.groupby(['Pclass', 'Survived'])['Survived'].count()

print(nyplot)

nyplot.plot(kind='bar')

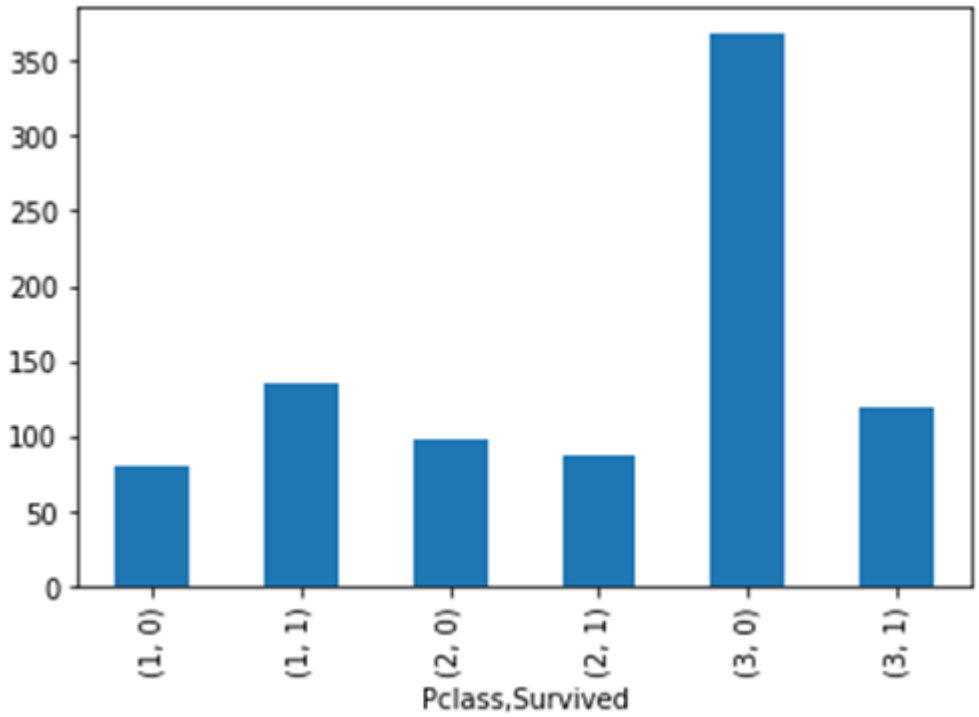

Således påviser søjlediagrammet at der på første klasse var 80 omkomne, på anden klasse var der 97 omkomne og på tredje klasse var der 368 omkomne. Dermed var 3 klasse den med flest omkomne

Slutteligt er endnu en pivot-tabel, der udelukkende viser fordelingen af overlevende i hver klasse. Først har vi lavet en ny dataframe, der består af kolonnerne, Survived og Class. Dernæst har vi

anvendt .groupby() til at visualisere fordelingen af overlevende samt omkomne på de forskellige klasser.

For at generere pivot-tabellen, anvender vi den nye dataframe, værdien af de overlevende, som bliver opstillet i en kolonne sat i forhold til de tre klasser.

For at få antallet af overlevende anvender vi sum(). Funktionen finder således summen af alle værdierne, bestående af 0 og 1, og fremviser disse i tabellen ud fra hver klasse. Igen anvender vi plot(kind='bar') for at visualisere resultaterne.

ny_df = df_titanic[['Survived','Pclass']]

print(ny_df)

ny_df.shape

tabel1= pd.pivot_table(ny_df, values= 'Survived', columns= 'Pclass', aggfunc= 'sum') #antal overlevende på de forskellige klasser

print(tabel1)

vistabel1 = tabel1.plot(kind='bar')

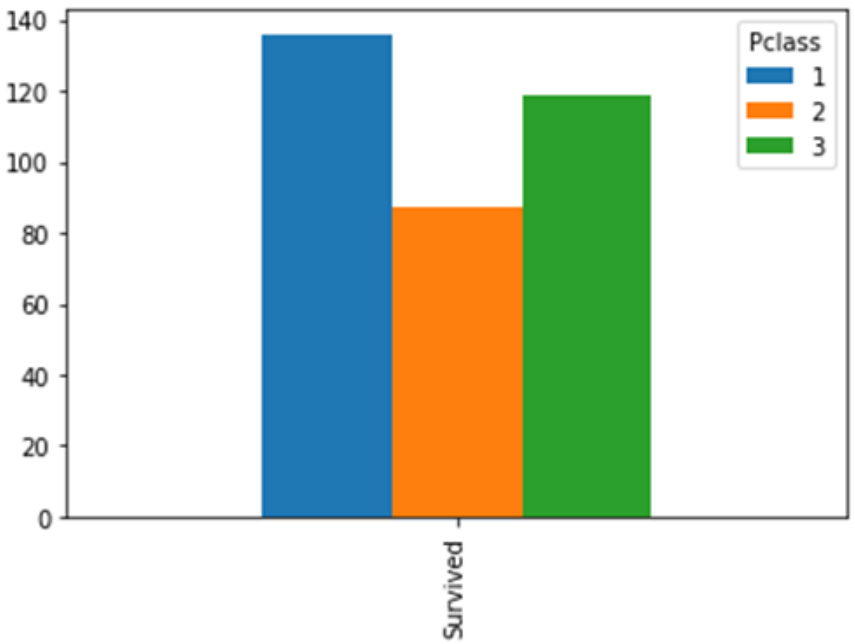

Overordene søjlediagram påviser således antal overlevende per klasse. De fleste overlevende på henholdvis første og tredje klasse (136 og 119). Mens de færrest overlevende var på anden klasse (87).

Litteraturliste

Pandas.pydata.org. (u.å). pandas.pivot_table. Lokaliseret d. 19. september 2019 på: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.pivot_table.html

Kode

```
# OPGAVE (1)  Åben filen i en tekst-editor og se på indholdet.

# OPGAVE (a)
# I filen ‘titanic.csv’, som er åbnet med Numbers, kan man anskue følgende datatyper, ‘interger’ og ‘float’, 'string'.
# Den førstnævnte angiver, at værdien er et heltal, den næste et decimaltal og sidstnævne et tekststykke.
# Endvidere er hele datasættet opdelt i 8 kolonner: ‘Survived’, ‘Pclass’, ‘Name’, ‘Sex’, ‘Siblings/Spouses Aboard’, ‘Parents/Children Aboard’ og ‘Fare’.
# De overlevende/omkomne bliver angivet som henholdsvis '1'/‘0’ (intergers).
# Dernæst kan man også se opdelingen af klasser, 1, 2 og 3 (interger), samt navne på passagerne og deres køn (strings).
# Derudover kan man også se deres alder, antal søskende, ægtefæller og forældre (interger) og billetprisen (float).

# OPGAVE (b)
# Når vi gennemgår Numbers-arket, kan vi se, at der ikke mangler data, eftersom der ikke forekommer tomme celler i dataframen.
# Manglende værdier vil fremstå som tomme celler i Numbers og kategoriseret som ‘NaN’ (Not a Number) i Python.
# Dette demonstreres også i næste opgave.

# OPGAVE (2)

# Her importeres pandas
import pandas as pd

# Her læser vi filen titanic med read_csv, da det er en csv-fil.
df_titanic = pd.read_csv('titanic.csv')
```

```
# Dernæst udskriver vi dataframen og kan se, at der i alt eksisterer 887 rækker og 8 kolonner, hvilket svarer til 887 passagerer og 8 kategorier.
print(df_titanic)


# Nu vil vi bruge describe() til at få et hurtigt overblik over diverse kolonner og generelle statistiske beregninger.
# Her kan vi eksempelvis se, at den højeste pris for en billet er 512,8 og den mindste pris er 0.
df_titanic.describe()

# klart overblik over alle 8 kategorier i for-loop, der gennemløber dataframen og udskriver kategorien for hvert genenmløb.
for i in df_titanic.columns:
    print(i)

# Her bruger vi shape() til at illustrer antallet af kolonner og rækker i dataframen.
print(df_titanic.shape)

# Denne funktion viser antallet af celler. Således kan man se antallet af værdier i hele dataframen
print(df_titanic.size)

# viser datatyper. Funktionen undersøger og definerer forskellige typer data i dataframen og fortæller, at der findes følgende: Int64, object, float64.
# Dette kan defineres som henholdsvis integer numbers, string, og float.
# Pandas referer til strings som object. (Kilde: https://pbpython.com/pandas_dtypes.html?fbclid=IwAR06-ND1itRz3rV4UNzihOOLj5IgtVpgZm2Z6FDVsdyVCe4UQhf7jgLb--Y)
print(df_titanic.dtypes)

# Undersøger om dataframen mangler data. Funktionen stiller spørgsmålet: Er der tomme celler i datasættet. Hvis nej, vil output være False og hvis ja, vil den returnere True.
```

```
df_titanic.empty

# Alternativ løsning til at finde missing data. Bruger funktionen isnull() og sum() til at finde missing data. Funktionen gennemår data for hver kolonne, og optæller antallet af True og False, da den ligeledes forsøger at undersøge, om værdien er 0.
# Såfremt funktionen finder tomme celler, vil den angive dem som True og lave en optælling af dette booleanske udtryk. Hvis funktionen ikke finder tomme celler, vil de blive angivet som False og tilskrevet værdien 0.
# Derved får vi en værdi ud fra hver kolonne som output, der viser tallet 0, eftersom der ikke forekommer tomme celler i dataframen.
print(df_titanic.isnull().sum())


# OPGAVE (3)

# Denne funktion udskriver antallet af overlevende, da den lægger summen af alle værdierne sammen.
# 0 er omkomne og 1 er overlevende.
# Således ved vi med sikkerhed at tallet, 342, er antallet af overlevende og er kategoriseret som tallet 1.
print(df_titanic['Survived'].sum())


# Denne funktion tæller antallet af hver unikke værdi i kolonnen.
# Her kan vi se både antallet af omkomne (0), 545, og overlevende (1), 342.
print(df_titanic['Survived'].value_counts())


# Overblik over passasegere på hver klasse. Vi har brugt samme funktion, der tæller antallet af hver unikke værdi.
print(df_titanic['Pclass'].value_counts())
```

```
# Alternativ måde at se antal rejsende inden for hver klasse med en variabel.
filter_classes=df_titanic['Pclass'].value_counts()
print(filter_classes)

# Gennemsnitsalder med mean()funktionen.
# Vi angiver en specifik kolonne i dataframen og bruger mean() funktionen.
average= df_titanic['Age'].mean()
# Her runder vi tallet til nærmeste heltal.
print(round(average))

# Vi bruger median(), således vi kan se median alderen.
print(df_titanic['Age'].median())

# Vi udskriver kolonnen Name, så vi kan få en oversigt over navnene.
print(df_titanic['Name'])

# Her kan vi få et overblik over den højeste billetpris ved hjælp af max() funktionen.
print(df_titanic['Fare'].max())

# Her vil output vise den laveste billetpris ved hjælp af min() funktionen.
print(df_titanic['Fare'].min())

# Her kan vi se gennemsnitsprisen på billetterne ved at bruge mean() igen.
print(df_titanic['Fare'].mean())


# OPGAVE (4)

# For at undersøge, hvorvidt der forekommer tilfælde, hvor passagererne har samme efternavn, har vi først og fremmest kreeret en ny variabel og dernæst benyttet .str.rsplit() funktionen.
# Denne funktion splitter kolonnen, Name, i et antal kolonner og opdelinger i forhold til en bestemt seperator.
```

# Først kan man definere, hvorvidt kolonnen skal opdeles efter en streng eller regulært udtryk i Pat.
# Dernæst hvor mange opdelinger, der skal forekomme i N, eg. Hvis n = 1, får man 2 opdelinger af dataen, således et navn freemstår som en liste med to elementer: forenavn og efternavn.
# Slutteligt kan man vælge i expand, om strengene skal udvides i separate kolonner baseret på booleanske udtryk, True og False.
# Hvis man ikke definerer Pat, vil funktionen, som standard, separere efter mellemrum, hvilket passer med separeringen af navnene.
# Vi har valgt kun at inkludere N og expand. N er sat til 1 og expand er True. Således får vi to kolonner med opdelingen, fornavne og efternavne.
# Slutteligt har vi udskrevet antal efternavne (kolonne 1, da kolonne 0 er fornavne) i den nye variabel sammenlagt med antallet af gentagelser, da value_counts tæller de unikke værdiers forekomst.
# kilde: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.Series.str.rsplit.html
df_new= df_titanic['Name'].str.rsplit(n=1, expand=True) #kolonner med efternavne
print (df_new)
df_new[1].value_counts() #navne + antal gentagelser

#En alternativ løsning på opgaven viser alle de efternavne, der går igen i dataframen.
#Først har vi lavet en variabel, som finder Names og splitter dem ved mellemrum bagfra.
lastnames=df_titanic.Name.str.split(' ').str[-1]
print(lastnames)

# Her kan vi se hele listen over alle efternavnene, alle 887.
print(lastnames.tolist())

# Her har vi oprettet to tomme liste variable, som vi ønsker at bruge senere.
unique=[]
repeat=[]

Vi har lavet en for-loop, der tager udgangspunkt i listen med alle efternavnene
Ved første for-loop runde leder funktionen efter et efternavn.

```
# Hvis efternavnet ikke findes i 'unique' listen i forvejen, bliver det tilføjet til den tomme unique liste.
# Ved anden for-loop runde, leder funktionen også først efter om efternavnet findes i 'unique' listen - og hvis det ikke gør, er det stadig unikt og skal tilføjes til den tomme liste
# Derimod hvis efternavnet allerede eksisterer i 'unique', går efternavnet videre til elif-statementet og spørger om efternavnet findes i repeat-listen - på samme måde tilføjes det til repeat listen, hvis navnet ikke er der i forvejen
# Resultatet ender ud med, at alle navne i repeat-listen kun bliver nævnt 1 gang - og vi kan derfor konkludere, at 133 navne ud af de ialt 887, bliver gentaget mere end 1 gang

for i in lastnames:
    if i not in unique:
        unique.append(i)
    elif i not in repeat:
        repeat.append(i)

print(sorted(repeat))
print(len(repeat))



# OPGAVE (5)

# Først har vi genereret en pivot-tabel med klasse, der viser antal rejsende inden for hver klasse (med brug af pandas funktioner.)
# I dette tabel-format kan man angive hvilken kolonne, der skal vises, og hvilken funktion, der skal behandle den. Dette har vi valgt at drage fordel af i vores tabel.
# aggfunc udgør den type funktion, man ønsker at anvende, hvilket vi har defineret som count, da vi skal have en optælling af alle rejsende opdelt i klasser.
# Kilde: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.pivot_table.html
class_tabel= df_titanic.pivot_table(columns='Pclass', aggfunc=({'Pclass':'count'}))
print(class_tabel)
#Her bruger vi plot(kind='bar'), således vi også kan få et visuelt output
```

```
class_tabel.plot(kind='bar')

#Antal overlevende/omkomne i hver klasse, hvor 0 er omkomne og 1 er overlevende. Funktionen optæller antallet for hver værdi i survived.
# I første klasse var der 80 omkomne
# I anden klasse 97
# I trejde klasse 368
# Dermed var trejde klasse den med flest omkomne.
nyplot = df_titanic.groupby(['Pclass', 'Survived'])['Survived'].count()
print(nyplot)
# Her har vi lavet en visuel fremstilling af pivot-tabellen.
nyplot.plot(kind='bar')

# Her har vi lavet en Pivot tabel, der udelukkende viser fordelingen af overlevende i hver klasse.
# Først har vi lavet en ny dataframe, der består af kolonnerne, Survived og Class. Dernæst har vi brugt .groupby() til at visualisere fordelingen af overlevende samt omkomne på de forskellige klasser.
# For at generere pivot-tabellet, vil vi anvende den nye dataframe, værdien af de overlevende, som bliver opstille i kolonne i forhold til de tre klasser.
# Denne pivot-tabel bruger sum(), således vi kan se antallet af overlevende.
# Funktionen funder summen af alle værdierne, bestående af 0 og 1, og fremviser dem tabellen ud fra hver klasse.
# Slutteligt har vi inkluderet plot(kind=‘bar'), for at demonstrere fordelingen i et søjlediagram.

ny_df = df_titanic[['Survived','Pclass']]
print(ny_df)
ny_df.shape
tabel1= pd.pivot_table(ny_df, values= 'Survived', columns= 'Pclass', aggfunc= 'sum') #antal overlevende på de forskellige klasser
print(tabel1)
# Her har vi lavet en visuel fremstilling af pivot-tabellen.
vistabel1 = tabel1.plot(kind='bar')
```

```
# Det sidste vi vil demonstrere er, hvor mange der i alt overlevede og omkom, ved brug af en for-loop.
# Den første funktion laver en liste over alle 1'ere og 0'ere - som skal bruges i for-loop funktionen.
count_people=df_titanic['Survived'].tolist()
print(count_people)

#Denne for-loop løber derfor igennem listen 'count_people', og tæller hvor mange der overlevede og hvor mange der døde
survived=0
not_survived=0
for i in count_people:
    if i == 0:
        not_survived = not_survived + 1
    elif i == 1:
        survived = survived + 1
print(survived)
print(not_survived)
```

Portfolio 2

Introduction

For this assignment we will be working with the “The Guardian” dataset. To define a research question, we looked through the dataset and found it to be news articles. We then limited the data, meaning the articles, to a month, here from September 1 to November 1, 2019. From this we got 1669 articles. In these we looked for repetitions and found that Boris Johnson’s name came up several times. This led us to the following research question:

Under which circumstances were 'Boris Johnson' discussed in relation to the ‘Politics’ category, in the Guardian from September 1 to November 1, 2019.

Our key findings

Task 1

For this task we printed the number of id’s/text’s/fields’ which are 1669, symbolizing the number articles in our chosen dataframe.

Task 2

To derive a document matrix, we used CountVectorizer to remove stopwords, added a token pattern with a regular expression and subsequently transformed the data to a matrix in our “vecfit” variable. Then, we can illustrate the amount of unique words that were tokenized, namely, 43713 words from our textcorpus.

We calculate the sparsity of our matrix to be 0.99, which signifies that out matrix is sparse. As the next step, we calculate the TF-IDF weighting of our matrix.
A key finding in this task is the previous and the tokenized word count. The previous is 2.330.313, while the tokenized is 1.055.035. We have used CountVectorizer dictionary stopwords and the regular expression for this.
Another key finding is the average length of a document. We calculated this to be 632,1 after removing the stopwords from the text.

Task 3

For this task we narrowed down our search and generated a query, focusing on ‘Politics’ in relation to Boris Johnson. We choose this topic in order to answer our research question. Hereafter, we created a matrix over our query to use for the next task.

Task 4

In relation to topic modelling, we made the following word cloud. These illustrate the top 10 words in four different components. Thus, it becomes evident that topics regarding brexit, government and the deal have been on the agenda during the two months, September and November. These comply with reality as they do in fact reflect current and well-debated topics in the UK. Therefore, by further assessing and interpreting the situation in the UK based on news, we can use our model to identity and reveal interesting topics that may set the scene for further research.

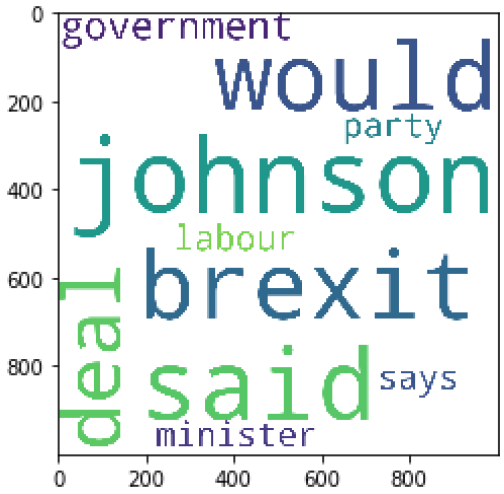

Conclusion

To answer our research question, from our topic modelling we can conclude that Boris Johnson is discussed in relation to politics, Brexit, the Labour party, government, minister and England. These topics makes sense as Boris Johnson is the newly appointed prime minister of England, and thereby a part of the government and the ongoing discussion of Brexit.

Kode

```
# Imports
## Task 1
import json
import os
import pandas
import requests
from os import makedirs
from os.path import join, exists
from datetime import date, timedelta

## Task 2
import pandas as pd
from nltk.corpus import stopwords
from nltk.tokenize import word_tokenize
import numpy as np
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.feature_extraction.text import TfidfTransformer
from nltk.probability import FreqDist

## Task 4
from sklearn.decomposition import LatentDirichletAllocation
from wordcloud import WordCloud
import matplotlib.pyplot as plt

''' Task 1 '''

# Here we download the data

ARTICLES_DIR = join('theguardian', 'collection')
makedirs(ARTICLES_DIR, exist_ok=True)
MY_API_KEY = 'bfeb3d66-1e24-4e0a-8082-1c6ee9e2a7b7'
```

```
API_ENDPOINT = 'http://content.guardianapis.com/search'
# We create a dictionary called my_'params' and set the values
# Boris Johnson will be our focus. Thus, we will import articles in relation to him.
# for the API's mandatory parameters
my_params = {
   'q' : 'boris+johnson',
   'from-date': "",
   'to-date': "",
   'order-by': "newest",
   'show-fields': 'all',
   'page-size': 200,
   'api-key': MY_API_KEY
}

# We choose to download the data with this start- and end date.
# We have chosen to download only one week of data to narrow down
# the text corpus.
start_date = date(2019, 9, 1)
end_date = date(2019, 11, 1)

dayrange = range((end_date - start_date).days + 1)
for daycount in dayrange:
   dt = start_date + timedelta(days=daycount)
   datestr = dt.strftime('%Y-%m-%d')
   fname = join(ARTICLES_DIR, datestr + '.json')
   if not exists(fname):
      print("Downloading", datestr)
      all_results = []
      my_params['from-date'] = datestr
      my_params['to-date'] = datestr
      current_page = 1
```

```
    total_pages = 1
    while current_page <= total_pages:
        print("...page", current_page)
        my_params['page'] = current_page
        resp = requests.get(API_ENDPOINT, my_params)
        data = resp.json()
        all_results.extend(data['response']['results'])
        current_page += 1
        total_pages = data['response']['pages']
    with open(fname, 'w') as f:
        print("Writing to", fname)
        f.write(json.dumps(all_results, indent=2))


# Here we read the data
directory_name = "theguardian/collection/"

ids = list()
strtexts = ""
texts = list()
allfields = list()
allheadlines = list()
allSections = list()


for filename in os.listdir(directory_name): #For ever file in the guardian collection, listdir every file in this collection - it returns an unsorted list of all the directories in the path..
   if filename.endswith(".json"): # If the file ends with json, open the collection as well as filenames as json files.
        with open(directory_name + filename) as json_file:
            data = json.load(json_file) #saves the json-files in a variable, names data.
            for article in data: #for every article in the variable data.
```

```
        id = article['id'] # id is defined as the articles ids
        headline = article['webTitle'] #the variable headline is defined as the html-title, 'webTitle',
in the corpus.
        sections = article['sectionName']# etc.
        fields = article['fields']
        text = fields['bodyText'] if fields['bodyText'] else ""
        ids.append(id) #appends the variable id to a list
        strtexts += text #adds text to the variable to create a string version
        texts.append(text) # creates a list version of all the texts
        allSections.append(sections)
        allfields.append(fields)
        allheadlines.append(headline)

print("Number of ids:", len(ids))
print("Number of texts:", len(texts), "Number of fields", len(allfields))


''' Task 2 '''

# We have generated a dataframe for a better overview of the dataset

dataframe = pd.DataFrame({'all_fields': allfields,
                          'all_headlines': allheadlines,
                          'all_texts': texts,
                          'section_ids': allSections})
dataframe.shape # (13713 rows and 5 columns)


# We will derive a document-term matrix for our collection.
# We remove stopwords and count the amount of words,
# and lastly convert the data to a matrix.
```

```
countvect = CountVectorizer(min_df = 1,
                            stop_words = stopwords.words('english'),
                            token_pattern = r'[a-zA-Z\-][a-zA-Z\-]{2,}')
vecfit = countvect.fit_transform(texts) # transforming data to matrix, vectors.

# We print a list over terms from the variable, texts, sorted according to their index, which is
produced by fit_transform
matrixwords = countvect.get_feature_names()
print(matrixwords)
matrixx = vecfit.toarray()
print(matrixx)
# Here we print the shape of our matrix
print(vecfit.shape) #1669, 43713

# Show words and index numbers
# Access the entire vocabulary to see what exactly was tokenized by calling
top_ordindex=countvect.vocabulary_
print(top_ordindex)

# Amount of words in new vocabulary - only unique words
print(len(countvect.vocabulary_))

# Calculating the matrix sparsity
sparsity = 1.0- np.count_nonzero(matrixx) / matrixx.size
print(sparsity)

# Result: 0.99.
# Thus, our matrix is sparse as its sparsity is greater than 0.5.



# TF-IDF weighting.
# Calculating the weight of the words by using scikit's tfidtransform
```

```
# on our previous document-term count matrix.
tfidfmodel = TfidfTransformer()
datafittransformer = tfidfmodel.fit_transform(vecfit)
print(datafittransformer.shape)
print(datafittransformer.toarray())


#How many documents = 1669
len(texts)

# Pre-processing
# Word count before and after pre-processing
# Tokenize loop

# We ensure that the text (as a string) is divided into words by using word_tokenize
tokenizedtext = word_tokenize(strtexts)
no_stopwords = []

# Then, we save the stopwords in a variable
stop_words = set(stopwords.words('english'))


# And create a loop, that goes thorugh all the words in the tokenized text and checks if it contains
stopwords. If not, it will be saved to a list.
for bestemtord in tokenizedtext:
    if bestemtord.lower() not in stop_words:
        if bestemtord.isalpha():
            no_stopwords.append(bestemtord)

print("Previous word count: ", len(tokenizedtext)) #2330313
print("Word count (removed stopwords and tokens): ", len(no_stopwords)) #1055036
```

```
# Average length of documents = 632.1 words - after tokenization
len(no_stopwords)/len(texts)


# Top 20 most common words in our collection. 'Johnson' and 'Brexit' are very popular words.
ferquencywords = FreqDist(no_stopwords)
top_topwords = ferquencywords.most_common(20)
print(len(top_topwords)) # gets total amount of topics
print(top_topwords)


# Distribution of articles in different topics
ferquencynewsgroups = FreqDist(dataframe['section_ids'])
top_newsgroups = ferquencynewsgroups.most_common(30)
print(len(top_newsgroups)) # gets total amount of topics
print(top_newsgroups)

''' Task 3 '''

#First, we create a query focusing on politics to explore the current agenda in relation to Boris Johnson.
terms = ['Politics']
terms

query = " ".join(terms)
query

# Then we create a matrix of our query, countvect
query_vect_counts = countvect.transform([query])
query_vect = tfidfmodel.transform(query_vect_counts)
query_vect
```

''' Task 4 '''

```
# We generated a topicmodel with one component since we are only focusing on politics in relation to Boris Johnson (whom we specified within our search parameters in the beginning)
# and make it replicable to ensure that the results will be the same each time we run the code.
topicModel_lda = LatentDirichletAllocation(n_components=1, random_state=0)
# We use our previous document-term count matrix, vecfit.
data_lda = topicModel_lda.fit_transform(vecfit)
np.shape(data_lda)
print(data_lda)

#We sort the term weights according to the 10 most popular words in a loop.
#then we get the topwords from countvect.getfeaturenames to show the words.
for i, term_weights in enumerate(topicModel_lda.components_):
    top_idxs = (-term_weights).argsort()[:10]
    top_words = ["%s (%.3f)" % (countvect.get_feature_names()[idx], term_weights[idx]) for idx in top_idxs]
    print("Topic %d: %s" % (i, ", ".join(top_words)))

#We included a wordcloud to present our results.
#This invovled creating a new variable that contained a dictionary of topwords and termweights.
#Then our wordcloud can show the most popular words according to their weight.
for i, term_weights in enumerate(topicModel_lda.components_):
    top_idxs = (-term_weights).argsort()[:10]
    top_words = [countvect.get_feature_names()[idx] for idx in top_idxs]
    word_freqs = dict(zip(top_words, term_weights[top_idxs]))
    wc = WordCloud(background_color="white",width=1000,height=1000,
max_words=10).generate_from_frequencies(word_freqs)
    plt.subplot(1, 1, i+1)
    plt.imshow(wc)
```

Thus, it becomes evident that topics regarding brexit, government and deal have on the agenda during these last months.
These comply with reality as they are in fact current and well-debated topics in the UK.

Portfolio 3

Beskrivelse af SMK Open

Vores valgte institution er Statens Museum for Kunst (SMK), da denne på nuværende tidspunkt fører et projekt der hedder SMK Open (2016-2020). Dette går ud på "...at stille hele Danmarks kunstsamling til fri afbenyttelse." (SMK Open, u.å.)) ved at digitalisere og tilgængeliggøre museets samling. SMK's formål er at alle danskere skal kunne benytte sig af kunsten og anvende den i "...sit eget liv og bruge på sine egne vilkår" (SMK Open, u.å.). Dermed har SMK tilgængeliggjort alt deres data ved at lade interessenter benytte SMK's egne API (SMK's API (beta-version), u.å.).
API (Application Programming Interface) er en tjeneste der muliggør at software kan tale med andet software. Det er med til at digitale tjenester kan udgive og offentliggøre deres data for andre interessenter på en struktureret måde (SMK's API (beta-version), u.å.).
SMK forestiller sig eksempelvis at deres data kan; tilgås uafhængigt af tid og rum; viderebearbejdes; nærstuderes i detaljer; deles; indsættes i alt fra bøger til forskningsartikler og skoleopgaver; og trykkes på alt fra plakater til sofapuder (SMK Open, u.å.).

Et konkret eksempel på anvendelse af SMK's data er applikationen Vizgu. Dette er en applikation der i samarbejde med diverse museer, heriblandt SMK, gør data tilgængelig for individet, mere specifikt er det en digital guide. Applikationen fungerer sådan at man blot skal pege sin telefon mod et kunstværk, hvorefter man vil få en masse yderligere oplysninger om det pågældende værk (vizgu, 2019; SMK Vizgu, u.å).
Endvidere har SMK i samarbejde med Hack4DK udforsket mulighederne ved de digitaliserede kunstværkerne med projekter, der trækker på kulturarvsdata (SMK Fridays: Deler kunsten, u.å.). Et eksempel på et projekt fra dette event indbefatter et spil, der tilskynder det enkelte individ at gætte titlerne på diverse malerier ud fra en 3D illustration (hack4dk, u.å.).
Således har SMK efterlevet deres mål om at tilgængeliggøre deres digitaliserede værker for offentligheden og dermed også opfordre samfundet til at anvende denne form for data til teknologiske og innovative måder at videregive og formidle kulturarven.

Opgave 2

Generering af URL

Vi har genereret vores URL, der søger efter statuetter i SMK's digitale database, som er følgende: https://api.smk.dk/api/v1/art/search?keys=statuette&rows=1000&encoding=json

Denne har vi indsat i JSON Beautifier, for at kunne beskrive indholdet.

a) Typer af metadata

Vi har identificeret forskellige slags metadata, som vi har kategoriseret i forhold til deskriptiv, administrativ og strukturel metadata.

De deskriptive metadata, bruges til at kunne identificere og beskrive indholdet på et overordnet plan, uden at gå i dybden med at forklare og vurdere (Digital Bevaring, u.å.).

De administrative metadata repræsenterer informationer om tid/dato, digitalisering og tekniske informationer og rettigheder (Digital Bevaring, u.å.).

De strukturelle metadata bruges til henholdsvist at vise og navigere samt kan det også være information om den interne organisering eller en rækkefølge af dokumenter (Digital Bevaring, u.å.).

Med henblik på førstnævnte, deskriptiv data, har vi eksempelvis observeret benævnelsen af årstal på værket: 'period', materiale: 'material', teknik: 'technique', kunstner: 'creator', fødselsår: 'creator_date_of_birth', dødsår: 'creator_date_of_birth', nationalitet: 'creator_nationality', titel: 'titles', noter: 'frame_notes' og 'content_notes', farver: 'colors', samt beskrivelse: 'content_description'.

Dernæst har vi i relation til administrativ metadata fundet id-numre: 'id', referencenumre: 'object number', digitaliseringsdage: 'created', rettigheder: 'public_domain', 'copyright', afdeling på museet: 'responsibledepartment', ændringsdato: 'modified', udstilling: 'exhibition', placering: 'shelfmark'.

Slutteligt har vi udpeget de strukturelle metadata i vores dataframe, bestående af antal dele: 'parts', kollektion: 'collection', dimensioner: 'dimensions' og hvad kunstværket er en del af 'parts of'.

b) Sammenligning af metadata med Dublin Core

Nedenstående er en oversigt over 15 metadata kerneelementer defineret af Dublin Core, som vi har sammenlignet med vores SMK datasæt og dermed kommet med eksempler på. Følgende 15 kerneelementer er hentet fra Dublin Cores hjemmeside (Dublin Core, 2019):

Contributor – “An entity responsible for making contributions to the resource.”

- På trods af at vi har kendskab til at SMK som organisation står for at tilbyde billeder, står dette ikke beskrevet i deres metadata.

Coverage – “The spatial or temporal topic of the resource, the spatial applicability of the resource, or the jurisdiction under which the resource is relevant.”

- Spatial: Vi har fundet lokationen på værket i form at. ‘shelfmark : 60875’.
- Temporal: I metadataen kan vi finde både digitaliseringsdag: ‘created’, ændringsdato: ‘modified’, start og slutdato på perioden: ‘start’, ‘end’, ‘period’, samt årstal på kunstværket: ‘acquisition_date_precision’.
- Jurisdiction: Selve afdelingen som værket hører ind under, er også nævnt som ‘responsible_department’.

Creator – “An entity primarily responsible for making the resource.”

- Kunstneren er nævnt under produktionsdetaljer om værket som ‘creator’.

Date – “A point or period of time associated with an event in the lifecycle of the resource.”

- Perioden’ som startdato: ‘start’ og slutdato: ‘end’ på perioden kan man finde i metadataen under objektet ‘production_date’.

Description – “An account of the resource.”

- Der findes diverse beskrivelser af værket i metadaten, eksempelvis: noter til indholdet: ‘notes’, indholdsbeskrivelse: ‘content_description’, noter til opsætningen: ‘frame_notes’, dimensioner: ‘dimensions’, og dokumentation: ‘documentation’.

Format – “The file format, physical medium, or dimensions of the resource.”

- SMK har inkluderet dimensionerne på deres værker, der indbefatter højde og centimeter under ‘dimensions’.

Identifier – “An unambiguous reference to the resource within a given context.”

- Her har SMK inkluderet ID numre: 'ID', referencenumre: 'object number', lokation: 'shelfmark' og 'current_location_name'.

Language – "A language of the resource."

- Derudover er forskellige sprogversioner af værkernes titler inkluderet i datasættet under elementet 'titles'.

Publisher – "An entity responsible for making the resource available."

- Vi fandt et element i metadataen under "notes", der står beskrevet som forskellige kataloger og hæfter - hvilket muligvis kan være dem, der er ansvarlige for at gøre statuetterne tilgængelige/dem der har givet SMK disse værker.

Relation – "A related resource."

- Der er metadata omkring relaterede værker i form af en note: 'notes' omkring eksempelvis kataloger, som værket indgår i, derudover står der også information om samlingen.

Rights – "Information about rights held in and over the resource."

- Vi fandt metadata, der angiver rettighederne omkring værket. Herunder er det synliggjort, hvilken form for kreditering værket er registreret med. Eksempelvis ift. copyright kreditering: 'public domæne', og rettigheder: "rights", hvor værdien kan være creative commons.

Source – "A related resource from which the described resource is derived."

- Kilden er beskrevet ved nogle af dem som "source", hvor de har tilhørende værdier som "THL", eller "Eva De La Fuente Pedersen".
- Under notering: 'notes' der står også ved specifikke værker, hvorfra de er erhvervet. Eksempel fra 'notes' er: 'Erhvervet af Herbert Melbye den 24. juni 1942 på auktion hos Winkel & Magnussen. kat. 54 (for DKK 517,50). Bruun Rasmussens bogfortegnelse nr. 35.'

Subject – "The topic of the resource."

- Kollektionen, udstillingen som værket er del af, indenunder 'content_description', får man nogle nøgleord og sætninger omkring værket, 'text' der beskriver værket.

Title – "A name given to the resource."

- Titlen på værket er ligeledes til stedet samt forskellige sproglige versioner af den, under 'title'.

Type – "The nature or genre of the resource."

- Dette er beskrevet under "titles", og herunder "type", hvoraf det kan være "Museum".

c) Statistiske beregninger

I dataen er værdier man kan anvende til statiske beregninger. Man kan blandt andet regne på årstal herunder digitaliseringsdato og produktionsdato. Med disse kan man eksempelvis lave en statistik over antal værker produceret i et bestemt år, eller en oversigt over værker digitaliseret på bestemte datoer. En anden værdi er periode, denne kan man eksempelvis anvende til at undersøge hyppigheden af perioder på SMK. Derudover kan man lave statistik over teknikker og materialer, eksempelvis hvor hyppigt et bestemt materiale eller en bestemt teknik er anvendt. Kunstnere i datasættet er også relevante at anvende, her kan man undersøge, hvor mange værker en bestemt kunstner har udstillet på SMK, eller hvilke materialer en bestemt kunstner anvender sig af hyppigst.

d) Eksempler på relevante spørgsmål til analyse af omtalte datasæt

- I hvilket årstal producerede man flest statuetter? (i vores sample bestående af 1000 værker)
    - Hvad er frekvensdistribueringen af statuetterne inden for hvert årstal?

- Hvor mange unikke kunstnere har skabt disse statuetter og med hvilket materialer?

- Hvordan er fordelingen af kunstnere der stadig lever og ikke lever?
- Hvordan er fordelingen af kunstnernes nationaliteter i vores datasæt? og hvilken nationalitet er hyppigst?

- Hvilken periode er den mest hyppigste inden for skulpturering?

Opgave 3

a) Importering, beskrivelse og rensning af datasæt

Vores datasæt består af 537 rækker og 49 kolonner før vi har renset det. Herunder er der adskillige kolonner, hvis værdier betegnes som 'NaN' not a number, da der mangler data - eksempelvis ved de kolonner, der starter med **'**image_'. Efter rensningen af dataframen har vi nu 537 rækker og 26 kolonner. Det vil sige at der er lige så mange statuetter som før, men med (49-26) = 23 færre kolonner (elementer/typer data). Hovedparten af de kolonner vi har fjernet, er dem, hvis værdier står som 'NaN', såsom billeder eller billedinformationer. Vi vil gerne fokusere på kolonner, der er mere konkrete og kan være behjælpelige i statistiske analyser, eksempelvis; kunstner, produktionsår, nationalitet, materialer.

I vores rensede datasæt er datatyperne 'objects', 'floats' og 'booleans'. Der 537 rækker, samt 26 kolonner. Vi har fravalgt visse kolonner da disse ikke er relevante for os, eksempler er**;** 'iiif_manifest', 'object_history_note', 'image_native' og 'image_thumbnail'.

Se bilag 1 for tabeller over rensning af datasættet.

Opgave 4

Beregning af udvalgt data

Vi kan lave en optælling af årstallene for at undersøge, hvornår der blev fremstillet flest statuetter. Samme metode kan benyttes med henblik på typer, hvor vi kunne observere at kategorier såsom statuetter, tegninger, skulpturer indgik i vores dataframe. Vi har specificeret statuette som nøgleord i vores søgning, hvilket ikke udelukker andre former for værker.

Endvidere har vi foretaget samme slags optælling af materialer og teknikker, således vi kunne skabe et overblik over de hyppigste anvendte.

Vi har udtrukket alle 'NaN' værdierne for at danne overblik over manglende værdier og udregnet summen for hver kolonne. Således kan vi se, at der forekommer adskillige celler i dataframen, hvor angivelse af tilhørende værdi mangler.

Vi har udregnet hvor mange af værkerne, der står som 'public domain', og fundet frem til at det er 245 ud af 537 værker. Således er der copyright rettigheder på hovedparten af værkerne i SMKs database.

Opgave 5

Producering af dataframe over udvalgt data

Vi har valgt at fokusere på acquisition_date_precision, da det viser årstallet for hvornår værket antageligvis blev overleveret til en kulturinstitution og/eller arkiveret

Først har vi lavet en optælling af disse årstal og fremstillet dem i procent. Dernæst har vi lavet en dataframe bestående af årstal i en kolonne og procentvise optællinger i en anden.

Opgave 6

Visualisering af data

Fra altair biblioteket har vi hentet funktionen, der kan visualisere vores dataframe. Vi har indsat dataframen og angivet år og forekomst som x og y i grafen.

Nedenstående er et udsnit af vores endelige graf. Vi har beskåret denne til fordel for det visuelle, da den fulde graf er mindre overskuelig. Den fulde graf kan findes i bilag 2.

Som fremvist i grafen kan man observere at denne falder og stiger flere steder (Bilag 2). Dog er den største stigning i 1914, der fortsætter indtil 1915, hvorefter den drastisk aftager i 1916. Dette kan bl.a. skyldes, at SMK indtil videre har digitaliseret flest værker fra denne periode og betyder nødvendigvis ikke, at der var flest produktioner af statuetter.

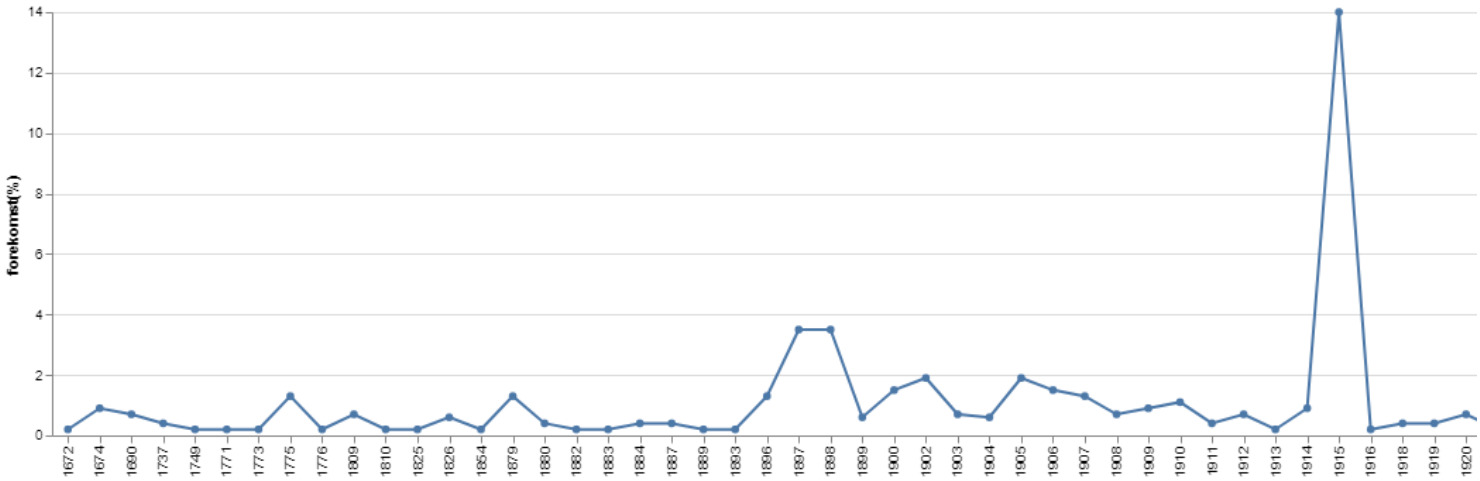

Litteraturliste

Digitalbevaring.dk (u.å.). Metadata - Hvad er metadata, og hvorfor er de vigtige for digital bevaring?. Lokaliseret d. 2 december 2019 på: https://digitalbevaring.dk/viden/metadata/

Dublin Core Metadata Initiative (2019). DCMI Metadata Terms. Lokaliseret d. 29 november på: https://www.dublincore.org/specifications/dublin-core/dcmi-terms/

Hack4dk (u.å). Lokaliseret d. 9. december 2019 på: https://hack4.dk/

SMK (u.å.). SMK's API (beta-version). Lokaliseret d. 28 november 2019 på: https://www.smk.dk/article/smk-api/

SMK Fridays: Deler kunsten (u.å). Lokaliseret d. 9. december 2019 på: https://www.smk.dk/event/smk-fridays-29-november/

SMK (u.å.). SMK Open. Lokaliseret d. 28 november 2019 på: https://www.smk.dk/article/smk-open/

SMK (u.å). Vizgu. Lokaliseret d. 9 december 2019 på: https://www.smk.dk/article/vizgu/

Vizgu (2019). Vizgu. Lokaliseret d. 9 december 2019 på: https://vizgu.com/

Bilag

Alle bilag er lavet i JupiterLab.

Bilag 1

Rensning af datasættet

Før rens af datasættet

	id	created	modified	acquisition_date_precision	responsible_department	content_description	frame_notes	materials	object_names	part_of	...	image_iiif_id
0	1180035377_object	2019-08-07T05:10:34Z	2019-08-12T09:33:32Z	1898-12-31	Samling og Forskning (KAS)	[Erstattet med KAS2229]	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[KAS2229, ORIG3096]	...	NaN
1	1180070230_object	2019-08-07T07:24:30Z	2019-08-08T08:29:02Z	1976-12-31	Samling og Forskning (KMS)	[Puys er et fiskerleje i nærheden af Dieppe.]	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'bronze'}]	[{'name': 'skulptur'}]	NaN	...	NaN
2	1180032239_object	2019-08-07T05:01:38Z	2019-08-12T09:32:26Z	1915-12-31	Samling og Forskning (KAS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[ORIG3101]	...	NaN
3	1180081678_object	2019-08-07T08:11:07Z	2019-08-12T09:50:58Z	1915-12-31	Samling og Forskning (KAS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[ORIG3097]	...	NaN
4	1180014421_object	2019-08-07T04:07:35Z	2019-08-08T08:33:53Z	1925-12-31	Samling og Forskning (KAS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[ORIG3104]	...	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...
532	1180058626_object	2019-08-07T06:37:21Z	2019-08-08T07:06:23Z	1968-12-30	Samling og Forskning (KKS)	NaN	[Baglædning: false, Mikroklimaramme: false]	NaN	[{'name': 'tegning'}]	NaN	...	NaN
533	1180017629_object	2019-08-07T04:17:22Z	2019-08-08T08:33:58Z	1970-12-31	Samling og Forskning (KKS)	NaN	[Baglædning: false, Mikroklimaramme: false]	NaN	[{'name': 'tegning'}]	NaN	...	NaN
534	1180060426_object	2019-08-07T06:44:35Z	2019-08-08T11:22:07Z	1968-12-30	Samling og Forskning (KKS)	NaN	[Baglædning: false, Mikroklimaramme: false]	NaN	[{'name': 'tegning'}]	NaN	...	NaN
535	1180004533_object	2019-08-07T03:37:36Z	2019-08-12T09:22:53Z	1690-01-01	Samling og Forskning (KMS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'alabast'}]	[{'name': 'friskulptur'}]	NaN	...	NaN
536	1180022529_object	2019-08-07T04:31:43Z	2019-08-12T09:29:04Z	1672-12-31	Samling og Forskning (KMS)	NaN	[Baglædning: true, Mikroklimaramme: false]	[{'material': 'lærred'}, {'material': 'olie'}]	[{'name': 'maleri'}]	[KMS3076]	...	https://iip.smk.dk/iiif/jp2/KMS3075.tif.recons...

537 rows × 49 columns

Efter rens af datasættet

```
df.head()
```

	id	created	modified	acquisition_date_precision	responsible_department	content_description	frame_notes	materials	object_names	part_of	...	object_number	public_domain
0	1180035377_object	2019-08-07T05:10:34Z	2019-08-12T09:33:32Z	1898-12-31	Samling og Forskning (KAS)	[Erstattet med KAS2229]	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[KAS2229, ORIG3096]	...	KAS384	False
1	1180070230_object	2019-08-07T07:24:30Z	2019-08-08T08:29:02Z	1976-12-31	Samling og Forskning (KMS)	[Puys er et fiskerleje i nærheden af Dieppe.]	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'bronze'}]	[{'name': 'skulptur'}]	NaN	...	KMShm3	True
2	1180032239_object	2019-08-07T05:01:38Z	2019-08-12T09:32:26Z	1915-12-31	Samling og Forskning (KAS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[ORIG3101]	...	KAS1910	False
3	1180081678_object	2019-08-07T08:11:07Z	2019-08-12T09:50:58Z	1915-12-31	Samling og Forskning (KAS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[ORIG3097]	...	KAS1906	True
4	1180014421_object	2019-08-07T04:07:35Z	2019-08-08T08:33:53Z	1925-12-31	Samling og Forskning (KAS)	NaN	[Baglædning: false, Mikroklimaramme: false]	[{'material': 'gips'}]	[{'name': 'statuette'}]	[ORIG3104]	...	KAS2049	False

5 rows × 26 columns

Bilag 2

Visualisering af den udvalgte data med procent i en graf.

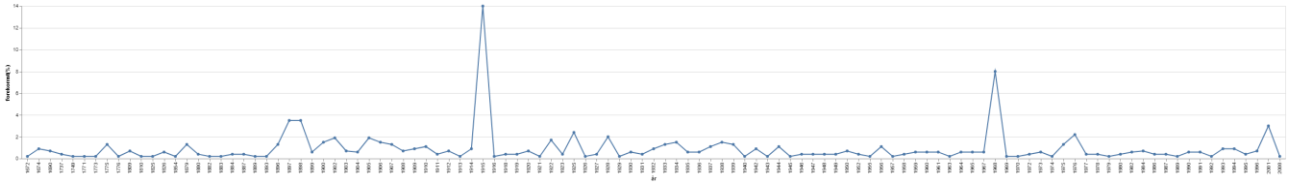

Kode

```
# Opgave 3: Ved hjælp af Pandas og request, importere nu jeres valgte datasæt.
import requests
import pandas as pd
import numpy as np
from pandas.io.json import json_normalize

api_search_url = 'https://api.smk.dk/api/v1/art/search'



# Vi opretter en 'dictionary' og angiver værdierne for SMKs API's parametre.
# Vi har valgt at vores nøgle-søgeord skal være statuetter.
params = {
    'keys': 'statuette',
    'rows': 1000,
}

# For at kunne bruge json beautifier, sørger vi for, at det står i JSON-format.
params['encoding'] = 'json'

# Her anmodes om vores søgning med SMKs API-URL samt de valgte parametre.
response = requests.get(api_search_url, params=params)

# Således kan vi printe URL'en:
print('Here\'s the formatted url that gets sent to the smk API:\n{}\n'.format(response.url))

json = response.json()

df = json_normalize(json['items'])

# Vi tjekker kolonnerne i head, her kan vi se, at der er 49 kolonner
df.head()
```

```
# Her kan vi se alle data-typerne
df.dtypes

# Fjerner kolonner
df.drop(['iiif_manifest','object_history_note','image_native','image_thumbnail','has_image','related_
objects','work_status','production_dates_notes','credit_line','current_location_name','content_person'
,'distinguishing_features','alternative_images','image_mime_type', 'image_iiif_id', 'image_iiif_info',
'image_width','image_height', 'image_size', 'image_cropped', 'image_orientation','exhibitions',
'labels'], inplace=True, axis=1)

# Navngiver kolonner
df.rename(columns={'created':'reg_year'}, inplace=True)
df.rename(columns={'object_names':'Type'}, inplace=True)
df.rename(columns={'number_of_parts':'number'}, inplace=True)
df.rename(columns={'acquisition_date_precision':'acqdate'}, inplace=True)

# Her kan vi se, at der nu er 26 kolonner
print(df.head())

# Formen på dataframen: 537 rækker og 26 kolonner
print(df.shape)


# Opgave 4: Udtræk og beregn

# Finder NaN værdier/missing values og returnerer summen.
# Således kan vi se, at der forekommer celler med manglende værdier
print(df.isnull().sum())


# Antal af værker, der er registreret som public domain.
df['public_domain'].sum()
```

```
# Kan se alle årstallene
alleårstal = []
for i in range(len(df['acqdate'])):
    alleårstal.append(df['acqdate'][i][0:4])
    alleårstal.sort()

from collections import Counter
Counter(alleårstal)

# Kun unikke årstal i datasættet
unikkeårstal =[]
def unique(alleårstal):
    x = np.array(alleårstal)
    unikkeårstal.extend(np.unique(x))

unique(alleårstal)
unikkeårstal #111

# Fordelingen af forskellige typer af værker inden for nøgleordet, statuettes.
df['Type'].value_counts()

# Fordelingen af værker registreret som public domæne. False 292 || True 245. Fleste er ikke.
df['public_domain'].value_counts()

# Hvor mange er public i alt
df['public_domain'].sum()

# Optællinger
df['acqdate'].str.extract(r'^(\d{4})', expand=False).value_counts() #vi udtrækker de specifikke årstal
og foretager en optælling
df['materials'].value_counts()
df['techniques'].value_counts(normalize=True)
```

```
# Opgave 5: Ny dataframe med value_counts

# Vi har lavet en procentvis optælling af acquisition date
optæl_årstal = df['acqdate'].str.extract(r'^(\d{4})',
expand=False).value_counts(normalize=True).mul(100).round(1) #får kun optællingerne
nydfdate = pd.DataFrame(optæl_årstal)

# Her har vi genereret en dataframe med årstal og optællingen
opdeltdf = pd.DataFrame({'år': nydfdate.index, 'forekomst(%)': optæl_årstal})



# Opgave 6: Visualisering af den nye dataframe. Dette fremvises i Jupytor Lab.

# Altair biblioteket importeres.
import altair as alt

# Ved x har vi sat år, som er den horisontale linje
# Ved y har vi sat forekomst i procent, dvs. optællingen, som vi indsatte i en dataframe, og vises i
den vertikale linje
alt.Chart(opdeltdf).mark_line(point=True).encode(
        x='år',
        y='forekomst(%)',
        tooltip= [alt.Tooltip('år'), alt.Tooltip('forekomst(%)')] #for hover effect
    ).properties(width=2500, height=300)
```

Etiske overvejelser

Natascha Rylander Bech, TGZ940

Antal tegn: 4690

Personhenførbare data

Personhenførbare data beskrives som informationer der kan henvise tilbage til en bestemt person. Dette gør sig også gældende, hvis de informationer man har, kun kan spores tilbage til en bestemt person, ved hjælp af andre informationer. Man kan derudover opdele personhenførbare data i to kategorier; ikke-følsomme og følsomme personoplysninger (Datatilsynet, u.å.).
Datatilsynet (u.å.) giver et overblik over hvad der kan kategoriseres som personhenførbare data, blandt andet; race og etnisk oprindelse, genetiske data, biometriske data, helbredsoplysninger med mere.

Ud fra vores tre portofolio-opgaver kan vi i portofolio 1 identificere etiske overvejelser i forhold til at arbejde med oplysninger om mennesker der enten har overlevet eller er blevet dræbt som følge af skibskatastrofen med Titanic, tilbage i 1912 (Wikipedia, 2019).
Man kan som det første tænke over den etiske problemstilling der opstår, når man behandler tragedier i tal. I datasættet bliver overlevende markeret med et 1-tal, mens de omkomne bliver markeret med et 0. Eftersom tragedien skete for mere end 100 år siden, kan man dog argumentere for at de fleste overlevende ikke lever længere. I sine etiske overvejelser er det dog stadig værd at tage med, at mennesker der har kendt de overlevende og omkomne stadig kan være i live.
Noget positivt ved dette, er dog stadig at tal gør komplicerede situationer nemmere at overskue i form af eksempelvis visuelle fremstillinger – der kan være med til at demonstrere hvor grufuld tragedien var, i og med at vise hvor mange der omkom.

Forskningsetiske retningslinjer

Nogle af de væsentlige forskningsetiske retningslinjer er blandt andet vigtigheden i at have fokus på; diversitet, undgå skade, pålidelighed, at være fair og ikke-diskriminerende, have respekt for andres arbejde og privatliv, samt at have professionelle kompetencer (ACM, 2018).

At være fair, undgå diskrimination og respektere diversitet handler på et overordnet niveau om at acceptere sociale og kulturelle forskelligheder, når man som programmør skal behandle og udgive data og kode. Det kan derfor gøre gavn som programmør, at kende til den sociale sammenhæng som programmeringsopgaven skal optræde i. Derudover er det i det hele taget en fordel at have en kommunikationsforståelse, således at man eksempelvis kan sikre sig en bedre sammenhæng mellem ”back-end” og ”front-end”.

I vores portofolio 3 kunne vi blandt andet identificere en problemstilling i at nogle statuetter var markeret som værende ikke-offentlige. Dette ses under faktoren ”public domain” – hvilket vi allerede i ”item 0” kunne se stod markeret som ”false” (bilag). Faktummet at en del af statuetterne er markeret om værende ikke offentlige, kan stille spørgsmål til de forskningsetiske regler i forbindelse offentlig tilgængelige data. Derimod er der også mange statuetter der er markeret med ”public domain: true”, hvilket eksempelvis kan være godkendt til offentlig brug grundet at ”copyright” er udløbet.

Maskinlæring og den objektive sandhed

Med hensyn til at lokalisere en objektiv sandhed i forbindelse med valg af metoder, der kan give forskellige resultater – må man erkende at der aldrig kan eksistere en 100% objektiv viden, da alting vil være fortolket og genereret af mennesker i sidste ende. Maskinlæring er et klart forsøg på at komme tættere på en objektiv programmeringssandhed – men her bliver man nødt til at huske at algoritmerne der former maskinlæringsprocessen, også er udviklet af mennesker (Anderson & Anderson, 2011).

I portofolio 2 tager vi udgangspunkt i The Guradian, hvilket er en engelsk nyhedshjemmeside (The Guardian, 2020), der tillader ”open soruce”. Dette betyder at det er software der er frit tilgængeligt for andre, således at det kan blive viderefortolket. Det kræver dog at man har en autoriseret adgang til koden og daten (Hampton et. al, 2015, s. 4).

Denne form for dataset kræver mere fortolkning fra start af, eftersom vi selv skulle definere søgeord, ”query” og tidsperioden for de tekster/artikler vi arbejdede med. Her kan fortolkning

komme til at betyde en del og variere fra programmør til programmør, alt efter valgte kriterier og behandling af data. Et godt eksempel er i opgave 2, hvor man skal rense teksterne for stopord og overflødige tegn. Her eksisterer der forskellige måder at gøre det på, der fjerner forskellige slags ord. Alt dette kan have betydning for opgave 4, der visuelt fremstiller hvilke ord/emner der bliver sat i sammenhæng med vores valgte søgeord/termer. Det er derfor vigtigt at have i mente at analyse og fortolkning kan have stor betydning for denne opgaves visuelle fremstilling, alt efter hvilke metoder og søgeord man fokuserer på.

Litteraturliste

Datatilsynet (u.å.). Lokaliseret d. 30/12-2019, på:
https://www.datatilsynet.dk/generelt-om-databeskyttelse/hvad-er-personoplysninger/

Wikipedia, Titanic (2019). Lokaliseret d. 30/12-2019, på:
https://da.wikipedia.org/wiki/RMS_Titanic

ACM Code of Ethics and Professional Conduct, skrevet af: Association for Computing Machinery, juni 2018:
https://www.acm.org/code-of-ethics

Anderson, M., & Anderson, S. L. (Eds.). (2011). *Machine ethics*. Cambridge University Press.

The Guardian (u.å.). Lokaliseret d. 30/12-2019, på:
https://www.theguardian.com/us

Hampton, S. E., S. S. Anderson, S. C. Bagby, C. Gries, X. Han, E. M. Hart, M. B. Jones, W. C. Lenhardt, A. MacDonald,W. K. Michener, J. Mudge, A. Pourmokhtarian, M. P. Schildhauer, K. H. Woo, and N. Zimmerman, 2015. The Tao of open science for ecology. Ecosphere 6(7):120.
http://dx.doi.org/10.1890/ES14-00402.1

Bilag

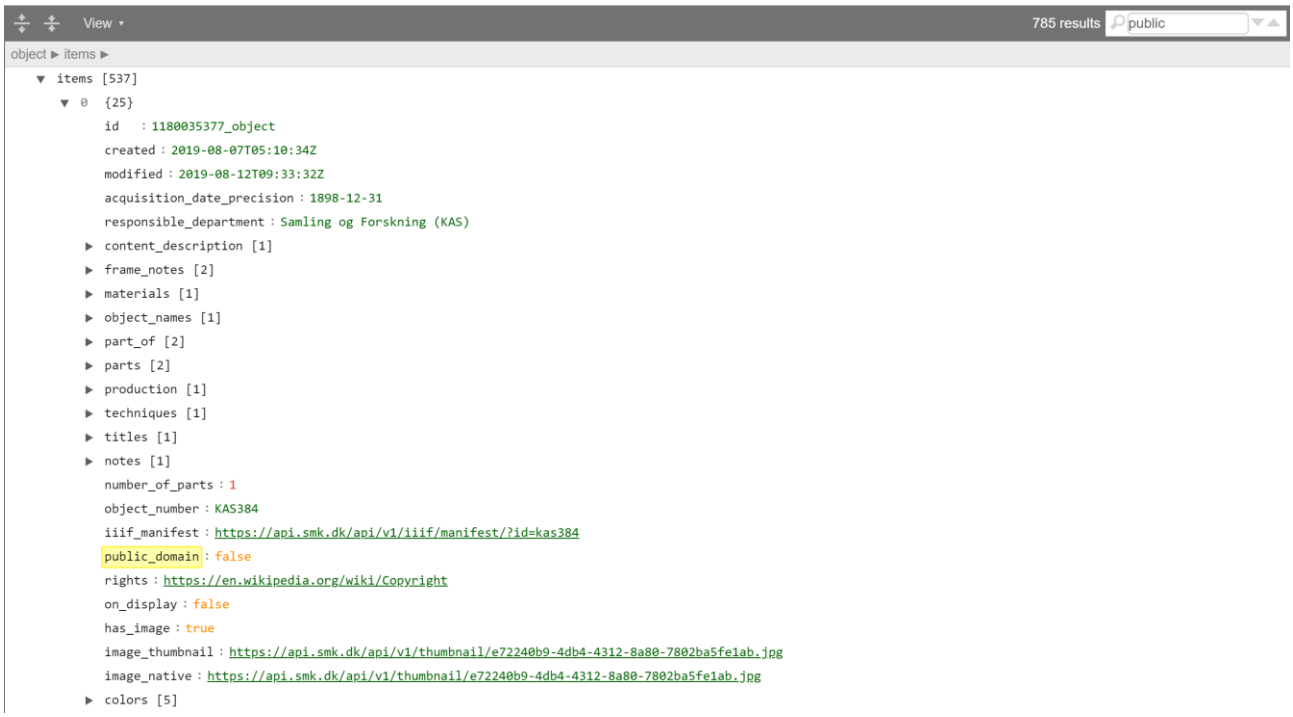
View
785 results
public
object ▶ items ▶
items [537]
0 {25}
id : 1180035377_object
created : 2019-08-07T05:10:34Z
modified : 2019-08-12T09:33:32Z
acquisition_date_precision : 1898-12-31
responsible_department : Samling og Forskning (KAS)
content_description [1]
frame_notes [2]
materials [1]
object_names [1]
part_of [2]
parts [2]
production [1]
techniques [1]
titles [1]
notes [1]
number_of_parts : 1
object_number : KAS384
iiif_manifest : https://api.smk.dk/api/v1/iiif/manifest/?id=kas384
public_domain : false
rights : https://en.wikipedia.org/wiki/Copyright
on_display : false
has_image : true
image_thumbnail : https://api.smk.dk/api/v1/thumbnail/e72240b9-4db4-4312-8a80-7802ba5fe1ab.jpg
image_native : https://api.smk.dk/api/v1/thumbnail/e72240b9-4db4-4312-8a80-7802ba5fe1ab.jpg
colors [5]